

# **COMPUTER VISION**

# **ULTRAVISION**

Anggota tim:

1. Farzan Aziz Fajarrudin
2. Adelia
3. Steven Tjayadi





# GLOSSARY

1. Project Background
2. Objective
3. Dataset
4. Model comparison theory
5. VGG 16
5. ResNet 50
6. GoogleNet
7. Perbandingan Model VGG 16, ResNet50, dan GoogleNet
8. Conclusion & Improvement

# PROJECT BACKGROUND

- Dalam era digital saat ini, teknologi pengenalan wajah (face recognition) telah berkembang pesat dan digunakan luas dalam berbagai sektor, mulai dari keamanan hingga personalisasi layanan.
- Proyek ini dilakukan sebagai langkah awal untuk memahami dan mengimplementasikan teknologi AI dalam bidang computer vision, khususnya melalui tugas *gender classification* berbasis citra wajah.
- Tujuan utama kami dengan proyek ini adalah
  - mengembangkan pemahaman praktis dalam membangun pipeline AI dari preprocessing data hingga evaluasi model,
  - membuka potensi penerapan AI dalam solusi berbasis citra di dunia nyata.



# Objektif

"Mengklasifikasi gender dari wajah manusia menggunakan CNN arsitektur VGG16, ResNet50, dan GoogLeNet"





# Dataset

**Nama:** Custom Face Gender Dataset

**Sumber:** CelebA dataset (kami ekstrak hanya total 202599 dataset yang digunakan)

**Format data:** JPG (178x218), diresize ke 224x224 pxl

**Label:** gender male dan gender female

**Hyperparameter tuning:**

- Optimizer Adam
- Learning rate 0.0001
- Batch size 32
- Epoch 10

**Augmentation:**


- Random Flip horizontal 0.5
- Unfreeze 3 layer terakhir



# Dataset

Male: 84434

Female: 118165






# MODEL COMPARISON

Model	Struktur Utama	Kelebihan	Kekurangan	Jumlah Parameter
VGG16	13 Conv + 3 FC	✓ Sederhana dan mudah diimplementasikan	✗ Jumlah parameter besar, boros memori dan komputasi	~138 juta
ResNet50	50-layer + Skip Connection	✓ Stabil saat training model dalam; mengatasi vanishing gradient	✗ Kompleksitas meningkat; butuh waktu training lebih lama	~25.6 juta
GoogLeNet	Inception Module (multi-scale convs)	✓ Efisien secara komputasi & memori; cocok untuk deployment ringan	✗ Struktur lebih kompleks; sulit dimodifikasi	~6.8 juta

# VGG16

Normalize



Komponen	Detail
Train/Test Split	80% / 20%
Loss Function	CrossEntropyLoss
Optimizer	Adam
Epochs	10
Batch Size	32
Device	GPU (CUDA)

	precision	recall	f1-score	support
Female	0.96	0.94	0.95	825
Male	0.92	0.94	0.93	577
accuracy			0.94	1402
macro avg	0.94	0.94	0.94	1402
weighted avg	0.94	0.94	0.94	1402

Analisa:

1. Train accuracy 1.0 --> overfitting
2. Gap terlalu besar antara train dan validation data, model terlalu hafal dengan data training
3. Train loss sangat rendah --> overfitting
4. Validation loss tidak stabil
5. Kesalahan lebih banyak pada prediksi female sebagai male dibanding sebaliknya
6. precision, recall dan f1 score sangat tinggi, kemungkinan overfitting




Kesimpulan:

Precision, recall dan f1 score sangat tinggi, kemungkinan overfitting, model pretrained besar VGG16 dengan dataset kecil sangat cepat menghafal



# VGG16

## Augmentation



Komponen	Detail
Train/Test Split	80% / 20%
Loss Function	CrossEntropyLoss
Optimizer	Adam
Epochs	10
Batch Size	32
Device	GPU (CUDA)

	precision	recall	f1-score	support
Female	0.96	0.94	0.95	825
Male	0.92	0.94	0.93	577
accuracy			0.94	1402
macro avg	0.94	0.94	0.94	1402
weighted avg	0.94	0.94	0.94	1402

Analisa:

1. Train accuracy 100%, validation accuracy 94% --> masih overfitting
2. Train Loss = sangat kecil, Val Loss tetap besar --> augmentasi belum menambah kompleksitas cukup

Kesimpulan:

Efek augmentasi tidak mempengaruhi hasil validation test, overfitting masih terjadi, augmentasi hanya bantu generalisasi di training

	Sebelum augment	Setelah augment
Accuracy	1	1
Female	0.96	0.96
Male	0.94	0.94
Train loss	Yes	Yes
Validation loss	Yes	Yes

## Rekomendasi Lanjutan


1. Eksperimen dengan jenis augmentasi lain, mungkin augmentasi masih terlalu ringan
2. Menambah epoch

# VGG16

Pred: Female | Label: Female



Pred: Male | Label: Male



Pred: Female | Label: Female




Pred: Male | Label: Male



Pred: Female | Label: Female




Pred: Female | Label: Female



Pred: Female | Label: Female



Pred: Female | Label: Female






Normalize

Augmentation

# RESNET50

Normalize



- Analisa:
- 1. Train accuracy naik dari 0.8 ke 0.9
  - 2. Validation accuracy lebih tinggi dari train di akhir epoch
  - 3. Tidak terjadi overfitting
  - 4. Train dan validation loss turun bersamaan
  - 5. Tidak ada underfitting/ overfitting
  - 6. Precision macro average 91% --> performa seimbang



Kesimpulan:  
ResNet50 mampu memberikan performa stabil tanpa overfitting, train dan validation loss/acuracy berjalan bersamaan.

Komponen	Detail
Train/Test Split	80% / 20%
Loss Function	CrossEntropyLoss
Optimizer	Adam
Epochs	10
Batch Size	32
Device	GPU (CUDA)


	precision	recall	f1-score	support
Female	0.92	0.93	0.92	825
Male	0.90	0.88	0.89	577
accuracy			0.91	1402
macro avg	0.91	0.91	0.91	1402
weighted avg	0.91	0.91	0.91	1402

# RESNET50

## Augmentation



Confusion Matrix - RESNET50 Gender Classifier post augmentation



- Analisa:
- 1. Train accuracy mencapai 1
  - 2. Validation accuracy naik
  - 3. Tidak ada gap signifikan antara train dan validation accuracy
  - 4. Train loss mendekati 0
  - 5. validation loss fluktuatif, ada indikasi overfitting
  - 6. Kesalahan berkurang setelah augmentasi

Kesimpulan:  
Data augmentasi berhasil di Resnet 50, akurasi dan f1 score meningkat tanpa overfitting berlebih. Model jadi lebih seimbang antara female dan male

Komponen	Detail
Train/Test Split	80% / 20%
Loss Function	CrossEntropyLoss
Optimizer	Adam
Epochs	10
Batch Size	32
Device	GPU (CUDA)

	precision	recall	f1-score	support
Female	0.97	0.96	0.96	825
Male	0.94	0.95	0.95	577
accuracy			0.96	1402
macro avg	0.96	0.96	0.96	1402
weighted avg	0.96	0.96	0.96	1402



# RESNET50

	Sebelum augment	Setelah augment
Accuracy	0.91	0.96
Female	0.92	0.96
Male	0.89	0.95
Train loss	Yes	Yes
Validation loss	Yes	Yes

Rekomendasi Lanjutan


1. Eksperimen dengan jenis augmentasi lain, bisa coba early stop

# RESNET50


Pred: Male | Label: Male



Pred: Female | Label: Female



Pred: Male | Label: Male



Pred: Female | Label: Female



Normalize

Pred: Male | Label: Male



Pred: Female | Label: Female



Pred: Male | Label: Male






Pred: Female | Label: Female



Augmentation

# GOOGLENET

Normalize



- Analisa:
1. Train accuracy naik dari 0.65 ke 0.88
  2. Validation accuracy lebih tinggi dari train di akhir epoch
  3. Tidak terjadi overfitting
  4. Train dan validation loss sama-sama turun
  5. Tidak ada underfitting/ overfitting
  6. Kesalahan terjadi 28 kasus dimana female diklasifikasi jadi male
  7. Female precision 95% akurat, Male precision 85% akurat
  8. f1 = 0.90 macro average --> performa seimbang




Kesimpulan:  
GoogleNet mampu mencapai akurasi tinggi 91% hanya dalam 10 epoch tanpa augmentation, kurva training stabil tidak ada overfitting

Komponen	Detail
Train/Test Split	80% / 20%
Loss Function	CrossEntropyLoss
Optimizer	Adam
Epochs	10
Batch Size	32
Device	GPU (CUDA)

	precision	recall	f1-score	support
Female	0.95	0.88	0.92	238
Male	0.85	0.94	0.89	174
accuracy			0.91	412
macro avg	0.90	0.91	0.90	412
weighted avg	0.91	0.91	0.91	412

# GOOGLNET

## Augmentation



- Analisa:
1. Train accuracy naik dari 0.7 ke 0.9
  2. Train dan validation loss turun bersamaan
  3. Validation loss lebih rendah dari train loss berarti proses augmentation bisa membantu
  4. Tidak terjadi peningkatan akurasi, malah terjadi penurunan
  5. Female precision membaik dibanding tanpa augmentation
  6. Accuracy turun dari 0.91 ke 0.89
  8. f1 macro accuracy juga turun dari 0.9 ke 0.89

Kesimpulan:  
Data augmentation tidak memberikan peningkatan performa, bahkan menurunkan akurasi, namun performa masih baik karena f1 score masih diatas 0.8 untuk kedua kelas

Komponen	Detail
Train/Test Split	80% / 20%
Loss Function	CrossEntropyLoss
Optimizer	Adam
Epochs	10
Batch Size	32
Device	GPU (CUDA)

Classification Report:					
	precision	recall	f1-score	support	
Female	0.92	0.89	0.91	238	
Male	0.86	0.90	0.88	174	
accuracy			0.89	412	
macro avg	0.89	0.89	0.89	412	
weighted avg	0.89	0.89	0.89	412	

# GOOGLENET

	Sebelum augment	Setelah augment
Accuracy	0.91	0.89
Female	0.92	0.91
Male	0.89	0.88
Train loss	Yes	Yes
Validation loss	Yes	Yes

Rekomendasi Lanjutan

1. Eksperimen dengan jenis augmentasi lain
2. Menambah epoch



# GOOGLNET

Pred: Female | Label: Female



Pred: Female | Label: Female



Pred: Female | Label: Female



Pred: Female | Label: Female



Normalize

Pred: Female | Label: Female




Pred: Female | Label: Female



Pred: Female | Label: Female



Pred: Male | Label: Female



Augmentation

# COMPARISON

Model	Augmentasi	Accuracy	f1 female/male	Macro f1	Train acc	Overfitting
VGG16	no	0.54	0.95/0.93	0.94	1.00	yes
VGG16	yes	0.94	0.95/0.93	0.94	1.00	yes
Googlenet	no	0.91	0.92/0.89	0.90	0.88	no
Googlenet	yes	0.89	0.91/0.88	0.89	0.91	no
Resnet50	no	0.91	0.92/0.89	0.91	0.90	no
Resnet50	yes	0.96	0.96/0.95	0.96	1.00	no

# CONCLUSION & IMPROVEMENT

1. Akurasi tertinggi ada pada model Resnet50 baik normal maupun hasil augmentasi
2. Googlenet sangat stabil tapi tidak mendapat benefit dari augmentasi
3. Minimum overfitting ada pada model googlenet sebelum augmentasi
4. Model VGG16 tidak efektif digunakan, bahkan setelah augmentasi, sehingga perlu regulariasi tambahan
5. Untuk project gender classification ini perlu pengembangan lebih lanjut terutama untuk bagian VGG dan googlenet agar mendapat pelatihan yang lebih cepat dan akurat.
6. Untuk improvement bisa ditambahkan model augmentasi lain sesuai model arsitekturnya, dan juga memperpanjang epoch 20-30 kali untuk melihat efek jangka panjang augmentasi

# THANK YOU

